



UNIVERSITÀ
DEGLI STUDI DI BARI
ALDO MORO

Università degli Studi di Bari
Aldo Moro
Dipartimento Interateneo di Fisica
Michelangelo Merlin



DIPARTIMENTO
INTERATENEEO
DI FISICA

AI nell'analisi dei dati

10 / 04 / 2026

Una lezione a cura di
Dr. **Mario Caruso**


Parte 1

Un po' di teoria...

AI

• Intelligenza Artificiale: cos'è?


L'**Intelligenza Artificiale** (IA) è la capacità delle macchine di imparare dai dati, riconoscere schemi e prendere decisioni in modo simile — ma non uguale — agli esseri umani.




«L'obiettivo dell'IA è far fare ai computer cose che, se fatte dall'uomo, richiederebbero intelligenza.»

John McCarthy (1927 – 2011), informatico statunitense e uno dei Padri dell'IA.



- **Intelligenza Artificiale: com'è fatta?**




DATI




MODELLO AI



• Intelligenza Artificiale: *Training*



**DATI
TRAIN**




MODELLO AI


- Pesi del modello
- Funzione di attivazione
- Ottimizzatore (Backpropagation)
- Minimizzazione funzione di errore

Il **training** di un modello di AI è il processo in cui il modello impara dai dati, modificando i propri parametri per ridurre gli errori e migliorare le sue previsioni.

- **Intelligenza Artificiale: *Testing***



**DATI
TEST**




**MODELLO AI
ADDESTRATO**



La fase di **testing** è il momento in cui si valuta il modello su dati mai visti prima, per verificare quanto funziona bene e quanto è in grado di generalizzare.

- **Intelligenza Artificiale: *Inferenza***

La fase di inferenza è il momento in cui il modello già addestrato viene usato per fare previsioni su nuovi dati.




**MODELLO AI
ADDESTRATO**




• Intelligenza Artificiale: le basi - *Training*

$x_1, x_2, \dots, x_n$ sono le caratteristiche, le variabili indipendenti, le features date in pasto al modello;
 $b, w_1, w_2, \dots, w_n$ sono i pesi del modello.



• Intelligenza Artificiale: le basi - *Training*


$x_1, x_2, \dots, x_n$ sono le caratteristiche, le variabili indipendenti, le features date in pasto al modello;
 $b, w_1, w_2, \dots, w_n$ sono i pesi del modello.



$$z = x_1 w_1 + x_2 w_2 + x_n w_n + b = \sum_{i=1}^n x_i w_i + b \rightarrow z \text{ è combinazione lineare di Features} \times \text{Pesi}$$

• Intelligenza Artificiale: le basi - *Training*

$x_1, x_2, \dots, x_n$ sono le caratteristiche, le variabili indipendenti, le features date in pasto al modello;
 $b, w_1, w_2, \dots, w_n$ sono i pesi del modello.




$$\mathbf{y} = \mathbf{f}(\mathbf{z}) \rightarrow \mathbf{y} \text{ è output del modello}$$

Con **f** funzione di attivazione che può essere...


Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




Leaky ReLU

$$\max(0.1x, x)$$



tanh

$$\tanh(x)$$




Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$


ReLU

$$\max(0, x)$$



ELU


$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



$$\mathbf{z} = x_1 w_1 + x_2 w_2 + x_n w_n + b = \sum_{i=1}^n x_i w_i + b$$

• Intelligenza Artificiale: le basi - *Training*

Output $y = f(z)$ va confrontato con la realtà y_{true} attraverso una funzione di errore (*Loss*).
Più grande l'errore, peggiore il risultato finale.



$$Loss (Error) \propto y_{true} - f(z)$$

L'errore *Loss*
va **MINIMIZZATO**.


• Intelligenza Artificiale: le basi - *Training*

Per minimizzare l'errore Loss, si usa l'**Ottimizzatore**, fondato sul meccanismo della **Backpropagation**.
I pesi del modello predittivo $b, w_1, w_2, \dots, w_n$ vengono **ritarati** in fase di **addestramento** per minimizzare la **Loss**.


Backpropagation

Per ogni peso w_i si calcola una sua nuova versione:

$$w'_i = w_i - \alpha \left(\frac{\partial \text{Loss}(x_1, x_2, \dots, x_n, w_1, w_2, \dots, w_i, \dots, w_n, b)}{\partial w_i} \right)$$




Ottimizzatore




• Intelligenza Artificiale: le basi - *Training*

$x_1, x_2, \dots, x_n$ sono le caratteristiche, le variabili indipendenti, le features date in pasto al modello;
 $b', w_1', w_2', \dots, w_n'$ sono i **NUOVI** pesi del modello.



• Intelligenza Artificiale: le basi - *Training*


$x_1, x_2, \dots, x_n$ sono le caratteristiche, le variabili indipendenti, le features date in pasto al modello;
 $b', w_1', w_2', \dots, w_n'$ sono i **NUOVI** pesi del modello.



$$z' = x_1 w_1' + x_2 w_2' + x_n w_n' + b' = \sum_{i=1}^n x_i w_i' + b' \rightarrow z' \text{ è combinazione lineare di Features} \times \text{NUOVI Pesi}$$

• Intelligenza Artificiale: le basi - *Training*


$x_1, x_2, \dots, x_n$ sono le caratteristiche, le variabili indipendenti, le features date in pasto al modello;
 $b', w_1', w_2', \dots, w_n'$ sono i **NUOVI** pesi del modello.



$$z' = x_1 w_1' + x_2 w_2' + \dots + x_n w_n' + b' = \sum_{i=1}^n x_i w_i' + b' \rightarrow z' \text{ è } \textit{combinazione lineare di Features} \times \textit{NUOVI Pesi}$$

• Intelligenza Artificiale: le basi - *Training*

$x_1, x_2, \dots, x_n$ sono le caratteristiche, le variabili indipendenti, le features date in pasto al modello;
 $b', w_1', w_2', \dots, w_n'$ sono i **NUOVI** pesi del modello.



$$y' = f(z') \rightarrow y' \text{ è } \textit{NUOVO output del modello}$$


NUOVO errore

$$Loss' (Error') \propto y_{true} - f(z')$$

$$z' = x_1 w_1' + x_2 w_2' + x_n w_n' + b' = \sum_{i=1}^n x_i w_i' + b' \rightarrow z' \text{ è } \textit{combinazione lineare di Features} \times \textit{NUOVI Pesi}$$

• Intelligenza Artificiale: le basi - *Training*

$x_1, x_2, \dots, x_n$ sono le caratteristiche, le variabili indipendenti, le features date in pasto al modello;
 $b', w_1', w_2', \dots, w_n'$ sono i **NUOVI** pesi del modello.



$$y' = f(z') \rightarrow y' \text{ è } \textit{NUOVO output del modello}$$

NUOVO errore

$$Loss' (Error') \propto y_{true} - f(z')$$

Ottimizzatore
E il ciclo continua...


$$z' = x_1 w_1' + x_2 w_2' + \dots + x_n w_n' + b' = \sum_{i=1}^n x_i w_i' + b' \rightarrow z' \text{ è } \textit{combinazione lineare di Features} \times \textit{NUOVI Pesi}$$

• Intelligenza Artificiale: le basi – *Testing & Inferenza*

$x_1, x_2, \dots, x_n$ sono le nuove features date in pasto al modello ADDESTRATO.

Sono nuovi esempi che il modello **NON** ha «visto» in Training.


$b_{def}, w_{1def}, w_{2def}, \dots, w_{n_{def}}$ sono i pesi FINALI del modello.




Il modello ora è in «fase di inferenza»: fornisce la sua predizione circa **nuovi dati**, sulla base di quelli su cui è stato addestrato.

Il modello è in fase di produzione.


• Intelligenza Artificiale: breve storia...




Percettrone, 1957




Reti neurali, 1986




Reti neurali convoluzionali, 1998



Intelligenza Artificiale
Generalizzata, ?




Transformers, 2017



Random Forest, 2001

- **Intelligenza Artificiale: wait ...**




Moderni Large Language Models calcolano circa 10^4 – 10^6 prodotti matrice-matrice al secondo per GPU (circa 10^4 GPU in parallelo), a seconda delle dimensioni e dell'ottimizzazione.
Training e inferenza di ChatGPT: circa 17,000,000,000.000 \$ all'anno (in aumento)

EDA


• Exploratory Data Analysis

Una Exploratory Data Analysis (EDA) è la fase iniziale in cui si esplorano i dati per capire cosa contengono, quanto sono affidabili e quali informazioni possono essere estratte, prima di applicare modelli o analisi più avanzate.




• Exploratory Data Analysis

Il primo passo è la raccolta dei dati. In questa fase si mettono insieme tutte le informazioni disponibili provenienti da diverse fonti. L'obiettivo è costruire un dataset completo su cui lavorare.




• Exploratory Data Analysis

Successivamente si passa alla pulizia dei dati. Qui i dati vengono sistemati per renderli coerenti e utilizzabili. Questo significa correggere errori, gestire valori mancanti e uniformare i formati. È una fase fondamentale, perché dati non puliti portano a risultati non affidabili.




• Exploratory Data Analysis

Una volta che i dati sono puliti, si esegue un'analisi descrittiva. In questa fase si utilizzano statistiche semplici per ottenere una prima comprensione del dataset. Si analizzano ad esempio medie, distribuzioni e frequenze, per capire la struttura generale dei dati.




• Exploratory Data Analysis

Dopo si può analizzare l'andamento nel tempo, se il dataset lo consente. Questa fase serve a individuare trend, variazioni e possibili pattern temporali. Permette di capire se una variabile cresce, diminuisce o segue comportamenti ricorrenti.




• Exploratory Data Analysis

Un altro passaggio importante è l'analisi delle correlazioni. Qui si studiano le relazioni tra le variabili per capire se esistono dipendenze o associazioni. Questo aiuta a individuare quali variabili possono essere rilevanti per spiegare un fenomeno.




• Exploratory Data Analysis

Infine si arriva alla visualizzazione. Tutte le informazioni raccolte vengono rappresentate graficamente per essere più facilmente interpretabili. I grafici permettono di sintetizzare i risultati e comunicarli in modo chiaro anche a chi non ha competenze tecniche.



• Exploratory Data Analysis

In sintesi, una EDA è un processo che parte da dati grezzi, li rende utilizzabili, ne studia le caratteristiche principali, individua pattern e relazioni, e infine li rappresenta in modo chiaro per supportare decisioni e analisi successive.



EDA & AI

L'uso dell'intelligenza artificiale nell'analisi dei dati introduce un cambiamento significativo nel modo in cui i dati vengono esplorati, interpretati e utilizzati per prendere decisioni.

• Modelli generativi del linguaggio: cosa sono?

I modelli generativi del linguaggio, chiamati **Large Language Models (LLM)**, sono sistemi di Intelligenza Artificiale progettati per **comprendere**, **produrre** e **manipolare** testo in **linguaggio naturale**.


Sono capaci di:

- ✓ rispondere a domande;
- ✓ scrivere testi e codici;
- ✓ riassumere documenti complessi;
- ✓ generare checklist o schemi;
- ✓ tradurre;
- ✓ analizzare contenuti tecnici;
- ✓ produrre materiali divulgativi;
- ✓ ...

The logo for Meta LLaMA 3, featuring a blue infinity symbol to the left of the word "Meta" in a dark blue sans-serif font, with "LLAMA 3" in a lighter blue sans-serif font below it.The logo for Google Gemini, featuring the multi-colored "G" logo to the left of the word "Gemini" in a black sans-serif font, with a small multi-colored star icon to the left of the word.The logo for OpenAI GPT-5, featuring a black knot-like icon above the text "GPT-5" in a bold black sans-serif font.The logo for Anthropic Claude, featuring a stylized orange star icon to the left of the word "Claude" in a black sans-serif font, with the letters "AI" in a large, bold, black sans-serif font above it.

Sono **assistenti** «**intelligenti**» che lavorano con il **linguaggio umano**.

• Modelli generativi del linguaggio: come sono fatti?



Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez*[†]
University of Toronto
aidan@cs.toronto.edu

Łukasz Kaiser*
Google Brain
lukaszkaiser@google.com

Illia Polosukhin*[‡]
illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.0 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature.

• EDA & AI: *PRO*

- 1. Maggiore velocità, scalabilità e capacità di individuare pattern complessi.**
- 2. Capacità di analizzare grandi quantità di dati in tempi molto ridotti:**
 - Dove un'analisi manuale richiederebbe ore o giorni, un sistema basato su AI può produrre risultati in pochi secondi o minuti.
 - Questo rende possibile lavorare su dataset molto più grandi e complessi.
- 3. Automatizzazione di molte fasi del processo di analisi:**
 - Pulizia dei dati
 - Feature engineering
 - Feature selection
- 4. Capacità di individuare pattern non evidenti:**
 - Gli algoritmi di machine learning riescono a cogliere relazioni non lineari e interazioni tra variabili che spesso sfuggono a un'analisi tradizionale.
 - Questo è particolarmente utile in contesti complessi come medicina, finanza o sistemi ambientali.
- 5. Supporto alle decisioni:**
 - I modelli predittivi consentono di stimare scenari futuri e quindi di prendere decisioni più informate.
 - In molti casi l'AI non si limita a descrivere i dati, ma permette di fare previsioni e simulazioni.

• EDA & AI: **CONTRO**

1. Mancanza di interpretabilità:

- Molti modelli, soprattutto quelli più complessi, funzionano come “scatole nere”.
- Questo rende difficile capire perché una certa decisione o previsione sia stata prodotta, aspetto critico in ambiti sensibili come la medicina.

2. Qualità dei dati:

- L'AI non corregge automaticamente errori concettuali nei dati.
- Se i dati sono incompleti, distorti o rumorosi, anche i risultati del modello saranno poco affidabili.
- In altre parole, la qualità dell'output dipende fortemente dalla qualità dell'input.

3. Rischio di bias:

- Se i dati utilizzati per addestrare i modelli contengono distorsioni, queste vengono apprese e amplificate dall'algoritmo.
- Questo può portare a risultati ingiusti o non rappresentativi.

4. Dipendenza dalla configurazione e dalle competenze tecniche:

- L'AI non è completamente automatica: richiede scelte metodologiche corrette, tuning dei parametri e validazione rigorosa.
- Un uso superficiale può portare a risultati fuorvianti.

5. Infine, c'è il rischio di sovra-automatizzazione.

- Affidarsi troppo all'AI può portare a perdere il controllo critico sull'analisi.
- È importante ricordare che l'AI è uno strumento di supporto, non un sostituto del ragionamento umano.

- *Take home message*

In sintesi, l'AI è uno strumento estremamente potente per l'analisi dei dati, capace di aumentare velocità e profondità delle analisi.

Tuttavia, deve essere utilizzata con consapevolezza, integrando sempre competenze statistiche e capacità critica per evitare errori e interpretazioni scorrette.

GRAZIE PER L'ATTENZIONE!

Parte 2

Un po' di esercizi...

- **Cosa faremo**

L'idea è di dare diversi prompt a tema «analisi dati» ad un LLM e studiarne la risposta.
Vedremo prima un prompt di base e poi un prompt più strutturato.

- Cosa useremo

Large Language Model
ChatGPT

Ambiente - Google Colab
<https://colab.research.google.com/>

- **Esercizio 1 – Curiosità**

SQL (Structured Query Language) è un linguaggio usato per lavorare con i database relazionali. Serve per gestire e interrogare dati strutturati, cioè organizzati in tabelle. Con SQL puoi inserire nuovi dati, modificarli, cancellarli e soprattutto fare query per estrarre informazioni utili. In pratica, SQL è lo strumento che ti permette di “fare domande” a un database e ottenere risposte precise.



- **Esercizio 1 – Prompt generico**

"Ho un dataset di pazienti con queste features patient_id, age, sex, glucose, blood_pressure diagnosis visit_date.

Scrivi una query SQL per analizzare il diabete nei pazienti"

5 minuti

• **Esercizio 1** – Prompt preciso

"Ho un dataset di pazienti con queste features patient_id, age, sex, glucose, blood_pressure diagnosis visit_date. glucose è una variabile numerica e diagnosis ha due livelli possibili: 'diabetes'/'no_diabetes'.


Scrivi una query SQL con i seguenti requirements:

- 1 considera solo pazienti con diagnosis = "diabetes";
 - 2 rimuovi righe con valori nulli di glucose o blood_pressure;
 - 3 crea tre fasce di età: 0-39; 40-50; 60+;
 - 4 calcola: glucose medio, blood_pressure medio, numero di pazienti;
 - 5 raggruppa i risultati per sesso e per fascia di età;
 - 6 ordina per fascia di età e per sesso;
- Forniscimi una query SQL pulita e production-ready."

10 minuti

- **Esercizio 2 – Curiosità**

Python è un linguaggio di programmazione semplice e molto diffuso, usato per analisi dati, intelligenza artificiale, sviluppo software e automazione. È apprezzato perché ha una sintassi chiara e permette di scrivere codice leggibile anche per chi non è esperto.



• Esercizio 2

Aprire il link:

https://colab.research.google.com/drive/1XC7q9NN6GSAiWNI2QK9qQb4NvHVBn_Vk?usp=sharing

Esercizio_2_Competenze_Trasversali_AI_analisi_dati.ipynb ☆ ☁

File Modifica Visualizza Inserisci Runtime Strumenti Guida

🔍 Comandi + Codice ▾ + Testo ▶ Esegui tutte ▾

[1] ✓ 0 s

```
import pandas as pd
import numpy as np
```

[3] ✓ 0 s

```
url = "https://raw.githubusercontent.com/mariocaruso96/AI_e_analisi_dati/main/glicemia.csv"
df = pd.read_csv(url)
```

[4] ✓ 0 s


```
df.head()
```

	patient_id	visit_date	glucose	age	sex
0	1	2023-01-01	105	45	M
1	1	2023-01-05	108	45	M
2	1	2023-01-09	110	45	M
3	1	2023-01-13	113	45	M
4	1	2023-01-17	115	45	M

Passaggi successivi: [Genera codice con df](#) [New interactive sheet](#)

• Esercizio 2

Creare una copia



The screenshot shows the Google Colab interface for a notebook titled "Esercizio_2_Competenze_Trasversali_AI_analisi_dati.ipynb". The "File" menu is open, displaying various options. The option "Salva una copia su Drive" is highlighted in yellow, and a red arrow points to it. Other visible options include "Trova su Drive", "Apri in modalità Playground", "Nuovo notebook su Drive", "Apri notebook" (with keyboard shortcut Ctrl+O), "Carica notebook", "Rinomina", "Sposta", "Sposta nel cestino", "Salva una copia come Gist GitHub", "Salva una copia su GitHub", "Salva" (with keyboard shortcut Ctrl+S), "Salva e blocca revisione" (with keyboard shortcut Ctrl+M S), "Cronologia delle revisioni", "Informazioni sul notebook", "Scarica", and "Stampa" (with keyboard shortcut Ctrl+P).


Below the menu, a portion of the notebook content is visible, showing a table with columns "age" and "sex".

age	sex
45	M
45	M
45	M
45	M
45	M

A button labeled "New interactive sheet" is also visible at the bottom of the notebook area.

• Esercizio 2

Lavorare sulla copia



The screenshot shows a Jupyter Notebook interface. The title bar at the top reads "Copia di Esercizio_2_Competenze_Trasversali_AI_analisi_dati.ipynb". Below the title bar is a menu bar with options: File, Modifica, Visualizza, Inserisci, Runtime, Strumenti, Guida. Below the menu bar is a toolbar with a search icon, "Comandi", "+ Codice", "+ Testo", and "▶ Esegui tutte". On the left side is a file explorer sidebar with icons for a menu, search, code editor, view, key, folder, and table. The notebook contains three code cells. The first cell imports pandas and numpy. The second cell defines a URL and reads a CSV file. The third cell displays the head of the DataFrame.

```
[ ] import pandas as pd
import numpy as np

[ ] url = "https://raw.githubusercontent.com/mariocaruso96/AI_e_analisi_dati/main/glicemia.csv"

df = pd.read_csv(url)

[ ] df.head()
```

	patient_id	visit_date	glucose	age	sex
0	1	2023-01-01	105	45	M
1	1	2023-01-05	108	45	M
2	1	2023-01-09	110	45	M
3	1	2023-01-13	113	45	M
4	1	2023-01-17	115	45	M

- **Esercizio 2 – Prompt generico**

"Ho un dataset con 10 pazienti con queste features: patient_id, visit_date, glucose, age, sex. Studiami la glicemia dei pazienti in termini di python. Crea il codice per Google colab."

10 minuti

• **Esercizio 2 – Prompt preciso**

"Ho un dataset con 10 pazienti con queste features: patient_id, visit_date, glucose, age, sex.

Il dataset contempla l'andamento della glicemia "glucose" nel tempo per 10 pazienti.

Forniscimi il codice python per creare una funzione che:

- 1) Prenda in input la serie temporale di un paziente;
- 2) Generi un plot che mostra l'andamento della glicemia "glucose" nel tempo "visit_date". Il plot deve avere sull'ascissa "visit_date" e sulle ordinate "glucose". L'asse delle ordinate deve essere compreso tra 0 e il valore massimo di glicemia più 20 punti. La serie temporale deve avere ogni punto con un marker a stellina e deve essere rosa se il sesso "sex" del paziente è F e blue se il paziente è M; il plot deve fornire nel titolo il numero di visite svolte dal paziente con il suo id.
- 3) Prenda in input una threshold che definisca un livello di "allerta". Il livello di allerta deve essere mostrato come una riga orizzontale rosso scuro nel plot.
- 4) Fornisca in output le differenze delta_glucose tra una visita e la precedente del paziente. Deve inoltre fornire una condizione di "stabilità" e di "instabilità" basata su una seconda threshold che la funzione deve ottenere in input. In particolare, se i delta_glucose sono sempre entro +- la threshold, la situazione è «stabile», altrimenti «instabile».

Crea il codice per Google colab.

20 minuti

- **Esercizio 3 – Curiosità**

Google Colab è un ambiente online gratuito che permette di scrivere ed eseguire codice Python direttamente nel browser, senza installare nulla sul proprio computer. Offre già librerie per data analysis e machine learning ed è collegato al cloud, quindi consente anche di usare risorse computazionali come GPU.



• Esercizio 3

Aprire il link:

<https://colab.research.google.com/drive/1Ihmcm6bYLxtpBAmPOo4C6PlttLxotqR#scrollTo=PKkhsVfJL5XC>

 Esercizio_3_Competenze_Trasversali_AI_analisi_dati.ipynb ☆ ☁

File Modifica Visualizza Inserisci Runtime Strumenti Guida

Q Comandi + Codice ▾ + Testo | ▶ Esegui tutte ▾

☰

🔍

<>

📷

🔑

📁

📄

[1]
✓ 0 s

```
import pandas as pd
import numpy as np
```

[2]
✓ 0 s

```
url = "https://raw.githubusercontent.com/mariocaruso96/AI_e_analisi_dati/main/dirty_diabetes.csv"

df = pd.read_csv(url)
```

[3]
✓ 0 s


▶ df.head()

	Unnamed: 0	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	0	6.0	98.0	58.0	33.0	190.0	34.0	0.430	43.0	0
1	1	2.0	112.0	75.0	32.0	0.0	35.7	0.148	21.0	0
2	2	2.0	108.0	64.0	0.0	0.0	30.8	0.158	21.0	0
3	3	8.0	107.0	80.0	0.0	0.0	24.6	0.856	34.0	0
4	4	7.0	136.0	90.0	0.0	0.0	29.9	0.210	50.0	0

Passaggi successivi: [Genera codice con df](#) [New interactive sheet](#)

• Esercizio 3

Creare una copia



The screenshot shows the Google Colab interface for a notebook titled "Esercizio_3_Competenze_Trasversali_AI_analisi_dati.ipynb". The "File" menu is open, and the option "Salva una copia su Drive" is highlighted with a yellow background and a red arrow pointing to it. Other menu options include "Trova su Drive", "Apri in modalità Playground", "Nuovo notebook su Drive", "Apri notebook" (Ctrl+O), "Carica notebook", "Rinomina", "Sposta", "Sposta nel cestino", "Salva una copia come Gist GitHub", "Salva una copia su GitHub", "Salva" (Ctrl+S), "Salva e blocca revisione" (Ctrl+M S), "Cronologia delle revisioni", "Informazioni sul notebook", "Scarica", and "Stampa" (Ctrl+P).


The notebook content displays a URL: `...com/mariocaruso96/AI_e_analisi_dati/main/dirty_diabetes.csv"` and a table of data:

BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
58.0	33.0	190.0	34.0	0.430	43.0	0
75.0	32.0	0.0	35.7	0.148	21.0	0
64.0	0.0	0.0	30.8	0.158	21.0	0
80.0	0.0	0.0	24.6	0.856	34.0	0
90.0	0.0	0.0	29.9	0.210	50.0	0

At the bottom of the notebook, there is a button labeled "New interactive sheet".

• Esercizio 3

Lavorare sulla copia



The screenshot shows a Jupyter Notebook interface. At the top, the title bar reads "Copia di Esercizio_3_Competenze_Trasversali_AI_analisi_dati.ipynb". Below the title bar, there is a menu bar with options: File, Modifica, Visualizza, Inserisci, Runtime, Strumenti, Guida. A search bar labeled "Comandi" is present, along with buttons for "+ Codice", "+ Testo", and "▶ Esegui tutte". On the left side, there is a sidebar with icons for file management and execution. The main area displays three code cells. The first cell contains the following code:

```
import pandas as pd
import numpy as np
```

The second cell contains the following code:

```
url = "https://raw.githubusercontent.com/mariocaruso96/AI_e_analisi_dati/main/dirty_diabetes.csv"
df = pd.read_csv(url)
```

The third cell contains the following code:

```
df.head()
```

The output of the third cell is a table showing the first five rows of the dataset:

	Unnamed: 0	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	0	6.0	98.0	58.0	33.0	190.0	34.0	0.430	43.0	0
1	1	2.0	112.0	75.0	32.0	0.0	35.7	0.148	21.0	0
2	2	2.0	108.0	64.0	0.0	0.0	30.8	0.158	21.0	0
3	3	8.0	107.0	80.0	0.0	0.0	24.6	0.856	34.0	0
4	4	7.0	136.0	90.0	0.0	0.0	29.9	0.210	50.0	0

- **Esercizio 3 – Prompt generico**

"Ho necessità di studiare il Pima Indians Diabetes Database svolgendo una EDA (exploratory data analysis) semplice.

Forniscimi il codice python per trovare informazioni da questo dataset. Crea il codice per Google colab."

20 minuti

• **Esercizio 3** – Prompt preciso

"Ho necessità di studiare il Pima Indians Diabetes Database svolgendo una EDA (exploratory data analysis) semplice. Forniscimi il codice python per:

1) studiare le caratteristiche essenziali del dataset in termine di shape, colonne, tipo, missing values presenti.

2) riempire i missing values di ogni colonna (se presenti) in tre maniere:

- a) media della feature;
- b) mediana della feature;
- c) con KNN imputer.

3) studiare la variabile "Outcome": comprendere lo sbilanciamento tra classi, produrre un bar plot in cui la classe minoritaria è colorata

in rosso e quella maggioritaria in blu

4) studiare le correlazioni tra variabili usando tutte le features a parte "Outcome":

- a) calcolare la correlazione di Pearson per ogni coppia di variabili continue, stabilendo la significatività della correlazione;
- b) produrre heatmap dei coefficienti di correlazione.

...

• Esercizio 3 – Prompt preciso

...

5) studiare gli outliers di ogni variabile continua: presa la distribuzione della feature, individuare il primo Q1 e il terzo quartile Q3, il range interquartile IQR, la mediana e i limiti "lower" e "upper", definiti rispettivamente come $\text{lower} = Q1 - 1.5 * IQR$ e $\text{upper} = Q3 + 1.5 * IQR$. Identificare gli outliers di ogni distribuzione come quei valori che sono numericamente sotto lower e/o sopra upper.

6) studiare la distribuzione di ogni feature continua: produrre un istogramma per ogni feature con colore differente.

- il binnaggio per ogni istogramma deve essere pari a 20. evitare l'uso della griglia sul plot. individuare i limiti lower e upper

- graficamente per ogni feature come due linee rosse verticali.

7) strategia per rimuovere gli outliers per ogni feature: al posto degli outliers inserire il valore mediano della distribuzione.

8) svolgere una Principal Component Analysis; ridurre il dataset studiando l'errore di ricostruzione tra il dataframe originale e quello ricostruito

- post PCA, considerando infine circa il 95% della varianza spiegata.

Crea il codice per Google colab."

40 minuti

***GRAZIE* A TUTTI!**